

CardioCare — 심장병 예측을 위한 종단간 ML 시스템

End-to-End Machine Learning System for Heart Disease Prediction

기계학습 기말 프로젝트 · 컴퓨터공학과

1. 문제 정의와 사용 목적


CardioCare는 UCI Heart Disease 데이터셋의 임상 변수(나이, 혈압, 콜레스테롤, 최대 심박수, ST 하강 등 13개)로부터 심장병 발병 가능성을 예측하여 심장 전문의의 의사결정을 보조하는 시스템이다. 출력은 0/1 분류와 위험 확률값이며, 이는 추가 검사가 필요한 환자를 우선 선별하는 참고 신호로 사용된다.

알리되, 결정하지 않는다 (inform, not decide). 이 시스템은 진단을 내리거나 치료를 결정하지 않는다. 최종 판단은 반드시 의료 전문가가 환자의 전체 맥락을 고려해 내린다. 모델은 그 판단을 위한 한 가지 입력일 뿐이며, 단독 의사결정 도구로 쓰여서는 안 된다(\$8 윤리 참조).

임상적으로 False Negative(심장병 환자를 정상으로 오분류)는 환자를 치료 기회로부터 배제하는 치명적 결과를 낳는다. 반면 False Positive는 추가 검사라는 비교적 가벼운 비용을 수반한다. 따라서 본 시스템은 recall(민감도)을 우선 지표로 설계했다.

2. EDA 핵심 결과

Cleveland·Hungarian·Switzerland·VA 4개 기관 데이터를 통합해 920행 × 13특성을 구성하고, 다중 클래스 타깃(num 0~4)을 이진화(0=정상, ≥ 1 =심장병)했다. 타깃 분포는 심장병 55.3% vs 정상 44.7%로 완만한 불균형(약 1.24:1)이다. 극단적이지 않으나, 임상적 비용 비대칭 때문에 단순 accuracy 대신 balanced accuracy와 recall을 핵심 지표로 채택하는 근거가 된다.



결측값은 기관별로 패턴이 뚜렷하다. slope-ca-thal은 Switzerland/VA에서 결측 비율이 50~90%에 달하며, Switzerland의 chol은 다수가 0(측정 누락)으로 기록돼 있다. 연속형 특성 boxplot에서는 chol과 trestbps에 이상치가 관찰된다.

연속형 특성 Boxplot (이상치 탐지)




그림 2. 연속형 특성 Boxplot — chol·trestbps의 이상치 및 chol=0 기록 누락 확인

3. EDA 결과에 근거한 전처리 결정

EDA에서 드러난 결측·이상치 패턴을 근거로, 정보 손실을 최소화하면서 데이터 누수 없이 새 데이터에 재적용 가능한 **sklearn.Pipeline**을 구성했다. 모든 변환기는 학습 fold에만 fit한다.

항목	결정	근거
연속형 결측	중앙값 대체	이상치·왜도에 강건
범주형 결측	최빈값 대체	가장 흔한 임상 상태로 보수적 대체
스케일링	StandardScaler	LR·SVC에 필요, 학습 fold에만 fit (누수 방지)
범주형 인코딩	OneHotEncoder	순서 없는 명목형 변수
이상치	삭제 안 함	920행 한정 데이터, 대체로 영향만 완화

핵심: 데이터 누수 방지. 스케일러·임퓨터·특성 선택기는 train/test 분할 이후 학습 데이터에만 fit하고, 테스트·추론 데이터에는 transform만 적용한다. 교차 검증 시에도 Pipeline 전체가 각 fold마다 새로 fit되어 검증 fold의 정보가 전처리에 새지 않는다.

4. 모델링 · MLflow 실험 및 최종 선택

데이터를 80/20으로 분할(시드 42, stratify)한 뒤, RandomForest 기반 **SelectFromModel**(threshold='mean')로 특성을 선택했다. OHE 변환 후 28차원 중 중요도 평균(0.036) 이상인 9개가 선택됐다(표 1). 5개 연속형(chol·age·thalach·oldpeak·trestbps) 전부와 흉통 유형(cp_4·cp_2)·운동유발 협심증(exang)이 포함됐으며, 이는 EDA에서 타깃과의 차이가 컸던 변수들과 일치한다.

선택 컬럼	원본 특성 / 의미	RF 중요도
chol	혈중 콜레스테롤 (mg/dl)	0.132
age	나이 (세)	0.113
thalach	최대 심박수 (bpm)	0.106
oldpeak	운동 ST 하강 (mm)	0.086
cp_4.0	흉통 유형 — 무증상	0.082
trestbps	안정 시 혈압 (mmHg)	0.073
exang_0.0	운동유발 협심증 없음	0.062
exang_1.0	운동유발 협심증 있음	0.054
cp_2.0	흉통 유형 — 비전형 협심증	0.041
(나머지 19개)	sex·fbs·restecg·ca·thal·slope 등	< 0.036 → 탈락

표 1. RandomForest SelectFromModel 특성 선택 결과 — 중요도 평균(threshold='mean', 0.036) 이상인 9개 선택, 나머지 19개 탈락.

Logistic Regression·SVC·Random Forest 3개 계열을 학습하고, 모든 실행을 MLflow(SQLite 백엔드)에 파라미터·지표·모델 아티팩트·계열 태그와 함께 기록했다. 전 모델에 5-fold 교차 검증을, 가장 유력한 RandomForest에는 RandomizedSearchCV(n_iter=20) 하이퍼파라미터 탐색을 적용했다.

모델	Bal. Acc	Precision	Recall	F1	CV Mean
Logistic Regression	0.820	0.849	0.824	0.836	0.779
SVC (최종 선택)	0.825	0.850	0.833	0.842	0.797
Random Forest	0.802	0.824	0.824	0.824	0.777
Random Forest (tuned)	0.808	0.832	0.824	0.828	0.789

표 2. 테스트셋 모델 성능 비교 (MLflow 기록). 강조 행이 최종 선택 모델.

최종 선택의 핵심 근거는 혼동행렬의 False Negative다. 아래 표는 4개 모델의 테스트셋(184건) 혼동행렬을 분해한 것이다.

모델	TN	FP	FN ↓	TP
Logistic Regression	67	15	18	84
SVC (최종 선택)	67	15	17	85
Random Forest	64	18	18	84
Random Forest (tuned)	65	17	18	84

표 3. 모델별 혼동행렬 분해 — FN(심장병 미탐지) 열 강조. SVC가 FN=17로 최소.

최종 모델: SVC. 임상적으로 가장 중요한 recall(0.833)이 최고이며, balanced accuracy(0.825)·F1(0.842)·CV 평균(0.797)도 가장 우수하다. 무엇보다 False Negative가 17건으로 4개 모델 중 가장 적다 — 심장병

환자를 놓치는 빈도가 가장 낮다는 뜻이다. 심장병 미탐지가 치명적인 본 문제에서 FN 최소화는 결정적 선택 기준이며, precision(0.850)도 충분히 높아 과도한 오경보 없이 균형을 유지한다.

5. 테스트와 패키징 — 무엇을, 왜

단위 테스트 (unittest 4개) — 사소하지 않은 실제 버그를 잡도록 설계:

테스트	검증 내용 / 잡아내는 버그
1. 예측 shape	predict() 행 수 = 입력 행 수. 배치 처리 시 행 누락/중복 탐지
2. 확률 범위·합	predict_proba $\in [0,1]$, 행합 1. 보정·인코딩 깨짐 탐지
3. 입력 범위 검증	chol $\in[0,600]$ 등 임상 범위 초과 입력 차단 (잘못된 단위/오타)
4. 결정론	고정 시드에서 동일 입력 → 동일 출력. 재현성·시드 누락 탐지

Docker. python:3.13-slim 기반으로 requirements 설치 → 코드·모델 복사 → 추론 엔트리포인트를 실행한다. docker build -t cardiocare:1.0 . 빌드 후 샘플 배치 입력으로 정상 추론된다. 비밀값은 포함하지 않는다.

CI (GitHub Actions). 모든 push에서 의존성 설치 후 unittest를 실행한다. main 브랜치의 green 유지를 목표로 한다.

피쳐 스토어 / 모델 레지스트리. 피쳐 스토어에는 oldpeak(ST 하강)를 등록한다 — 타깃 상관이 높고 특성 선택에서 항상 채택되는 안정적 피쳐로, ECG 장비에서 자동 갱신되므로 최신성 관리가 필요하다. 모델 레지스트리에는 recall 값을 메타데이터로 기록해, '기존 배포 모델보다 recall이 낮은 버전은 Production 승격 불가'라는 안전 게이팅을 자동화한다.

6. 드리프트 결과 및 재학습 / 피드백 루프

테스트셋의 chol 평균을 +30, 분산을 1.5배로 인위 이동시킨 뒤, 각 연속형 특성에 대해 학습 분포와 `scipy.stats.ks_2samp`를 수행했다.

특성	KS 통계량	p-value	드리프트 플래그
age	0.041	0.96	—
trestbps	0.037	0.99	—
chol	0.286	6.6e-11	플래그 (p<0.05)
thalach	0.058	0.71	—
oldpeak	0.041	0.96	—

표 4. KS 검정 결과 — 드리프트를 주입한 chol만 정확히 플래그됨.

검정은 드리프트를 주입한 chol만 정확히 탐지했고($p=6.6e-11$), 손대지 않은 특성은 모두 $p \geq 0.05$ 로 플래그되지 않아 오탐 없이 작동함을 확인했다. 입력 드리프트는 성능 저하로 이어져, balanced accuracy가 0.825 → 0.807로 떨어졌다(단일 이동 기준 2.2%).




그림 3. 합성 타임스탬프 기반 드리프트 모니터링 — chol 평균이 점증할수록 balanced accuracy 하락(상단), KS p-value 급락(하단, 로그 스케일).

재학습 / 피드백 전략

- 트리거 기반 재학습: 핵심 특성의 KS $p < 0.05$ 가 일정 기간 지속되거나, 라벨 확보 후 balanced accuracy가 임계치 이하로 떨어지면 재학습을 트리거한다.
- 정기 재학습: 트리거가 없어도 분기별로 최신 임상 데이터로 재학습해 점진적 드리프트에 대비한다.
- 폭주 피드백 루프 위험: 모델 예측을 그대로 라벨로 재사용하면, 모델이 놓친 양성(FN)이 학습 데이터에서도 음성으로 굳어져 recall이 자기강화적으로 악화된다. 이를 막으려면 재학습 라벨은 모델 출력이 아니라 의사의 확진/추적 결과 같은 실제 정답만 사용해야 한다.

- Human-in-the-loop 지점: (1) 경계 확률(예: 0.4~0.6) 구간은 의사 검토로 라우팅, (2) 재학습된 모델은 recall 게이팅 통과 후 사람이 승인해야 배포, (3) 드리프트 알람은 자동 재배포가 아니라 담당자에게 통지된다.

7. 서빙 선택: Model-as-a-Service

본 시스템은 Model-as-a-Service(MaaS)를 선택한다. 병원 EMR이 환자 임상값을 중앙 추론 API로 전송하면 위험 점수를 반환하는 구조다.

기준	MaaS 선택 근거
지연 시간	심장병 선별은 실시간(ms) 요구가 아닌 진료 중 수초 내 응답으로 충분 → 서버 추론 적합
모델 업데이트	모델 업데이트를 병원 통제하의 보안 서버에 중앙 집중 → 감사·접근통제·규정 준수 용이. 단, 전송 구간 암호화와 PHI 최소 수집은 필수
업데이트 주	재학습 모델을 단일 엔드포인트에 즉시 배포 → 전 사용자가 동일 최신 버전 사용, 기기별 배포 불필요

On-Device는 오프라인 동작과 데이터 미전송이라는 장점이 있으나, 모델 갱신 배포가 기기마다 분산되고 버전 파편화·드리프트 모니터링이 어렵다. 병원 환경에서는 중앙 통제와 감사 가능성이 더 중요하므로 MaaS가 적합하다.

8. 한계, 윤리적 고려, 추가 작업

한계

- 표본이 920행으로 작고 4개 기관에 한정 → 다른 인구집단으로의 일반화가 제한적이다.
- slope-ca-thal의 높은 결측을 대치로 메웠으므로, 해당 특성의 신호가 약화됐을 수 있다.
- 1999년 전후 데이터로, 현재 임상 분포와 시점 드리프트가 존재할 수 있다.

윤리적 고려

CardioCare는 의사를 대체하지 않고 보조한다(inform, not decide). 오분류의 비용이 환자 안전과 직결되므로, 예측은 항상 의료 전문가의 검토를 거쳐야 한다. 성별·연령 등 민감 변수에 따른 성능 편향 점검과, 환자에게 'AI 보조 사용' 사실을 고지하는 절차가 운영 단계에서 필요하다. recall을 우선했어도 놓치는 환자(FN)는 여전히 존재하므로, 음성 결과가 곧 안전을 보장하지 않음을 사용자에게 명확히 전달해야 한다.

1주가 더 주어진다면

- 결정 임계값을 0.5가 아닌 recall 목표(예: ≥ 0.90)에 맞춰 보정하고 PR 곡선으로 운영점 선택.
- SHAP 기반 설명을 추가해 의사가 예측 근거를 검토할 수 있게 함.
- 성별·연령 하위 그룹별 공정성 지표(subgroup recall)를 측정하고 보고.
- MLflow Model Registry와 실제 드리프트 대시보드를 연동.

부록 A. AI 도구 사용 공개

본 프로젝트에서 AI 코딩 도우미(Claude)를 보일러플레이트 작성과 디버깅 보조 용도로 사용했다. 구체적으로는 sklearn Pipeline·MLflow·unittest·Dockerfile의 표준 구조 초안 작성, reportlab 보고서 레이아웃, pandas 버전 호환 오류 디버깅에 활용했다. 데이터 전처리·모델 선택·지표 해석·드리프트 전략 등 모든 핵심 의사결정과 결과 해석은 직접 검토·검증했으며, 제출한 모든 코드와 결과에 대해 본인이 책임진다.