

CardioCare — 심장병 예측을 위한 종단간 ML 시스템

End-to-End Machine Learning System for Heart Disease Prediction

기계학습 기말 프로젝트 · 컴퓨터공학과

1. 문제 정의와 사용 목적


CardioCare는 UCI Heart Disease 데이터셋의 임상 변수(나이, 혈압, 콜레스테롤, 최대 심박수, ST 하강 등 13개)로부터 심장병 발병 가능성을 예측하여 심장 전문의의 의사결정을 보조하는 시스템이다. 출력은 0/1 분류와 위험 확률값이며, 이는 추가 검사가 필요한 환자를 우선 선별하는 참고 신호로 사용된다.

알리되, 결정하지 않는다 (inform, not decide). 이 시스템은 진단을 내리거나 치료를 결정하지 않는다. 최종 판단은 반드시 의료 전문가가 환자의 전체 맥락을 고려해 내린다. 모델은 그 판단을 위한 한 가지 입력일 뿐이며, 단독 의사결정 도구로 쓰여서는 안 된다(\$8 윤리 참조).

임상적으로 False Negative(심장병 환자를 정상으로 오분류)는 환자를 치료 기회로부터 배제하는 치명적 결과를 낳는다. 반면 False Positive는 추가 검사라는 비교적 가벼운 비용을 수반한다. 따라서 본 시스템은 recall(민감도)을 우선 지표로 설계했다.

2. EDA 핵심 결과

Cleveland·Hungarian·Switzerland·VA 4개 기관 데이터를 통합해 920행 × 13특성을 구성하고, 다중 클래스 타깃(num 0~4)을 이진화(0=정상, ≥ 1 =심장병)했다. 타깃 분포는 심장병 55.3% vs 정상 44.7%로 완전한 불균형(약 1.24:1)이다. 극단적이지 않으나, 임상적 비용 비대칭 때문에 단순 accuracy 대신 balanced accuracy와 recall을 핵심 지표로 채택하는 근거가 된다.



결측값은 기관별로 패턴이 뚜렷하다. slope-ca-thal은 Switzerland/VA에서 결측 비율이 50~90%에 달하며, Switzerland의 chol은 다수가 0(측정 누락)으로 기록돼 있다. 연속형 특성 boxplot에서는 chol과 trestbps에 이상치가 관찰된다.




그림 2. 0 sentinel 정규화 후 연속형 특성 Boxplot

3. EDA 결과에 근거한 전처리 결정

EDA에서 드러난 결측·이상치 패턴을 근거로, 정보 손실을 최소화하면서 데이터 누수 없이 새 데이터에 재적용 가능한 **sklearn.Pipeline**을 구성했다. 모든 변환기는 학습 fold에만 fit한다.

항목	결정	근거
0 sentinel	NaN 변환	trestbps-chol-thalach의 생리적으로 불가능한 0 처리
연속형 결측	중앙값 대체	이상치·왜도에 강건
범주형 결측	최빈값 대체	가장 흔한 임상 상태로 보수적 대체
스케일링	StandardScaler	LR·SVC에 필요, 학습 fold에만 fit (누수 방지)
범주형 인코딩	OneHotEncoder	순서 없는 명목형 변수
이상치	삭제 안 함	920행 한정 데이터, 대체로 영향만 완화

핵심: 데이터 누수 방지. 스케일러·임퓨터·특성 선택기는 train/validation/test 분할 이후 학습 데이터에만 fit하고, validation-test-추론 데이터에는 transform만 적용한다. 교차 검증 시에도 Pipeline 전체가 각 fold마다 새로 fit되어 검증 fold의 정보가 전처리에 새지 않는다.

4. 모델링 · MLflow 실험 및 최종 선택

데이터를 train/validation/test=60/20/20으로 분할(시드 42, stratify)한 뒤, RandomForest 기반 **SelectFromModel**(threshold='mean')로 9개 특성을 선택했다. 모든 변환과 특성 선택은 학습 fold 안에서만 fit된다.

선택 컬럼	RF 중요도
age	0.136
thalach	0.117
chol	0.096
oldpeak	0.080
cp_4.0	0.079
trestbps	0.074
exang_0.0	0.059
exang_1.0	0.057
cp_2.0	0.040

표 1. RandomForest SelectFromModel 특성 선택 결과.

Logistic Regression·SVC·Random Forest 3개 계열을 학습하고, 모든 실행을 MLflow(SQLite 백엔드)에 파라미터·지표·모델 아티팩트·계열 태그와 함께 기록했다. 전 모델에 5-fold 교차 검증을, RandomForest에는 RandomizedSearchCV(n_iter=20)를 적용했다. 후보 비교에는 validation만 사용하고 test는 최종 선택 후 한 번만 평가했다.

모델	Val Bal. Acc	Precision	Recall	F1	CV Mean
LogisticRegression (선택)	0.801	0.817	0.833	0.825	0.771
SVC	0.773	0.790	0.814	0.802	0.754
RandomForest	0.778	0.792	0.824	0.808	0.775
RandomForest_tuned	0.778	0.792	0.824	0.808	0.790

표 2. Validation 성능 비교 (MLflow 기록). 강조 행이 최종 선택 모델.

최종 선택 후 train+validation 데이터로 다시 학습하고, 보지 않은 테스트셋 184건을 한 번 평가했다.

모델	TN	FP	FN ↓	TP
LogisticRegression	62	20	20	82

표 3. 독립 테스트셋의 최종 혼동행렬.

최종 모델: LogisticRegression. 독립 테스트셋에서 balanced accuracy 0.780, precision 0.804, recall 0.804, F1 0.804를 기록했다. 테스트 결과를 모델 선택에 사용하지 않았으므로 이 수치를 최종 일반화 성능 추정치로 해석한다. 기관 하나를 통째로 제외하는 leave-one-site-out 검증의 balanced accuracy는 0.728 ± 0.054 로, 새 기관 일반화의 불확실성을 별도로 보고한다.

5. 테스트와 패키징 — 무엇을, 왜

단위 테스트 (unittest 7개) — 실제 데이터·추론 결함을 잡도록 설계:

테스트	검증 내용 / 잡아내는 버그
-----	-----------------

1. 예측 shape	predict() 행 수 = 입력 행 수. 배치 처리 시 행 누락/중복 탐지
2. 확률 범위·합	predict_proba ∈ [0,1], 행합은 약 1. 보정·인코딩 깨짐 탐지
3. 입력 범위 검증	chol∈[1,600] 등 임상 범위 초과 입력 차단 (잘못된 단위/오타)
4. 결정론	고정 시드에서 동일 입력 → 동일 출력. 재현성·시드 누락 탐지
5. 결측 sentinel	생리적으로 불가능한 0 측정값이 NaN으로 정규화되는지 검증
6. 추론 검증 연결	inference.py가 범위·범주 오류를 예측 전에 실제 차단하는지 검증
7. 숫자 문자열 입력	CSV 숫자 문자열이 수치형으로 정규화돼 추론되는지 검증

Docker. python:3.13-slim 기반으로 requirements 설치 → 코드·모델 복사 → 추론 엔트리포인트를 실행한다. docker build -t cardiocare:1.0 . 빌드 후 샘플 배치 입력으로 정상 추론된다. 비밀값은 포함하지 않는다.

CI (GitHub Actions). 모든 push에서 unittest, Docker build, 샘플 컨테이너 추론을 실행한다. main 브랜치의 green 유지를 목표로 한다.

피처 스토어 / 모델 레지스트리. 피처 스토어에는 oldpeak(ST 하강)를 등록한다 — 현재 실험의 특성 선택에서 채택됐고 임상적 의미가 명확하며, ECG 장비에서 자동 갱신되므로 최신성 관리가 필요하다. 모델 레지스트리에는 recall 값을 메타데이터로 기록해, '기존 배포 모델보다 recall이 낮은 버전은 Production 승격 불가'라는 안전 게이팅을 자동화한다.

6. 드리프트 결과 및 재학습 / 피드백 루프

테스트셋의 chol 평균을 +30, 분산을 1.5배로 인위 이동시킨 뒤, 각 연속형 특성에 대해 학습 분포와 `scipy.stats.ks_2samp`를 수행했다.

특성	KS 통계량	p-value	드리프트 플래그
age	0.0408	9.63e-01	—
trestbps	0.0405	9.68e-01	—
chol	0.2489	1.14e-06	플래그
thalach	0.0578	7.10e-01	—
oldpeak	0.0411	9.64e-01	—

표 4. KS 검정 결과 — 드리프트를 주입한 chol만 정확히 플래그됨.

검정은 드리프트를 주입한 chol만 플래그했다. 그러나 balanced accuracy는 0.780 → 0.780로, 이 시뮬레이션에서는 즉각적인 성능 저하가 관찰되지 않았다. 따라서 분포 드리프트 탐지와 성능 저하를 동일시하지 않고, 실제 라벨 기반 성능 모니터링을 별도로 유지해야 한다.




그림 3. 합성 타임스탬프 기반 드리프트 모니터링 — chol 평균이 점증할수록 KS p-value는 급락하지만 balanced accuracy는 단조 하락하지 않음.

재학습 / 피드백 전략

- 트리거 기반 재학습: 핵심 특성의 KS $p < 0.05$ 가 일정 기간 지속되거나, 라벨 확보 후 balanced accuracy가 임계치 이하로 떨어지면 재학습을 트리거한다.
- 정기 재학습: 트리거가 없어도 분기별로 최신 임상 데이터로 재학습해 점진적 드리프트에 대비한다.
- 폭주 피드백 루프 위험: 모델 예측을 그대로 라벨로 재사용하면, 모델이 놓친 양성(FN)이 학습 데이터에서도 음성으로 굳어져 recall이 자기강화적으로 악화된다. 이를 막으려면 재학습 라벨은 모델 출력이 아니라 의사의 확진/추적 결과 같은 실제 정답만 사용해야 한다.

- Human-in-the-loop 지점: (1) 경계 확률(예: 0.4~0.6) 구간은 의사 검토로 라우팅, (2) 재학습된 모델은 recall 게이팅 통과 후 사람이 승인해야 배포, (3) 드리프트 알람은 자동 재배포가 아니라 담당자에게 통지된다.

7. 서빙 선택: Model-as-a-Service

운영 확장안으로 Model-as-a-Service(MaaS)를 선택한다. 현재 저장소 구현은 입력 검증이 포함된 CSV 배치 추론 CLI이며, 병원 EMR 연동 중앙 API는 다음 배포 단계의 목표 구조다.

기준	MaaS 선택 근거
지연 시간	심장병 선별은 실시간(ms) 요구가 아닌 진료 중 수초 내 응답으로 충분 → 서버 추론 적합
모델 연산량	모델 연산량을 병원 통제하의 보안 서버에 중앙 집중 → 감사·접근통제·규정 준수 용이. 단, 전송 구간 암호화와 PHI 최소 수집은 필수
업데이트 주재학습	모델을 단일 엔드포인트에 즉시 배포 → 전 사용자가 동일 최신 버전 사용, 기기별 배포 불필요

On-Device는 오프라인 동작과 데이터 미전송이라는 장점이 있으나, 모델 갱신 배포가 기기마다 분산되고 버전 파편화·드리프트 모니터링이 어렵다. 병원 환경에서는 중앙 통제와 감사 가능성이 더 중요하므로 MaaS가 적합하다.

8. 한계, 윤리적 고려, 추가 작업

한계

- 표본이 920행으로 작고 4개 기관에 한정 → 다른 인구집단으로의 일반화가 제한적이다.
- slope-ca-thal의 높은 결측을 대치로 메웠으므로, 해당 특성의 신호가 약화됐을 수 있다.
- 1999년 전후 데이터로, 현재 임상 분포와 시점 드리프트가 존재할 수 있다.

윤리적 고려

CardioCare는 의사를 대체하지 않고 보조한다(inform, not decide). 오분류의 비용이 환자 안전과 직결되므로, 예측은 항상 의료 전문가의 검토를 거쳐야 한다. 성별·연령 등 민감 변수에 따른 성능 편향 점검과, 환자에게 'AI 보조 사용' 사실을 고지하는 절차가 운영 단계에서 필요하다. recall을 우선했어도 놓치는 환자(FN)는 여전히 존재하므로, 음성 결과가 곧 안전을 보장하지 않음을 사용자에게 명확히 전달해야 한다.

1주가 더 주어진다면

- 결정 임계값을 0.5가 아닌 recall 목표(예: ≥ 0.90)에 맞춰 보정하고 PR 곡선으로 운영점 선택.
- SHAP 기반 설명을 추가해 의사가 예측 근거를 검토할 수 있게 함.
- 성별·연령 하위 그룹별 공정성 지표(subgroup recall)를 측정하고 보고.
- MLflow Model Registry와 실제 드리프트 대시보드를 연동.

부록 A. AI 도구 사용 공개

본 프로젝트에서 AI 코딩 도우미(Claude, OpenAI Codex)를 보일러플레이트 작성과 디버깅 보조 용도로 사용했다. 구체적으로는 sklearn Pipeline·MLflow·unittest·Dockerfile의 표준 구조 초안 작성, 데이터 누수 점검, 입력 검증, reportlab 보고서 레이아웃과 버전 호환 오류 디버깅에 활용했다. 데이터 전처리·모델 선택·지표 해석·드리프트 전략 등 모든 핵심 의사결정과 결과 해석은 직접 검토·검증했으며, 제출한 모든 코드와 결과에 대해 본인이 책임진다.