

CardioCare — 심장병 예측을 위한 종단간 ML 시스템

End-to-End Machine Learning System for Heart Disease Prediction

기계학습 기말 프로젝트 · 컴퓨터공학과

1. 문제 정의와 사용 목적

CardioCare 는 UCI Heart Disease 데이터셋의 임상 변수(나이, 혈압, 콜레스테롤, 최대 심박수, ST 하강 등 13 개)로부터 심장병 발병 가능성을 예측하여 심장 전문의의 의사결정을 보조하는 시스템이다. 출력은 0/1 분류와 위험 확률값이며, 이는 추가 검사가 필요한 환자를 우선 선별하는 참고 신호로 사용된다.

알리되, 결정하지 않는다 (inform, not decide). 이 시스템은 진단을 내리거나 치료를 결정하지 않는다. 최종 판단은 반드시 의료 전문가가 환자의 전체 맥락을 고려해 내린다. 모델은 그 판단을 위한 한 가지 입력일 뿐이며, 단독 의사결정 도구로 쓰여서는 안 된다(\$8 윤리 참조).

임상적으로 False Negative(심장병 환자를 정상으로 오분류)는 환자를 치료 기회로부터 배제하는 치명적 결과를 낳는다. 반면 False Positive 는 추가 검사라는 비교적 가벼운 비용을 수반한다. 따라서 본 시스템은 recall(민감도)을 우선 지표로 설계했다.

2. EDA 핵심 결과

Cleveland·Hungarian·Switzerland·VA 4 개 기관 데이터를 통합해 920 행 × 13 특성을 구성하고, 다중 클래스 타겟(num 0~4)을 이진화(0=정상, ≥ 1 =심장병)했다. 타겟 분포는 심장병 55.3% vs 정상 44.7%로 완만한 불균형(약 1.24:1)이다. 극단적이지 않으나, 임상적 비용 비대칭 때문에 단순 accuracy 대신 balanced accuracy 와 recall 을 핵심 지표로 채택하는 근거가 된다.




그림 1. 타겟 클래스 분포 — 심장병(1) 55.3%, 정상(0) 44.7%

결측값은 기관별로 패턴이 뚜렷하다. slope-ca-thal 은 Switzerland/VA 에서 결측 비율이 50~90%에 달하며, Switzerland 의 chol 은 다수가 0(측정 누락)으로 기록돼 있다. 연속형 특성 boxplot 에서는 chol 과 trestbps 에 이상치가 관찰된다.




그림 2. 0 sentinel 정규화 후 연속형 특성 Boxplot

3. EDA 결과에 근거한 전처리 결정

EDA 에서 드러난 결측·이상치 패턴을 근거로, 정보 손실을 최소화하면서 데이터 누수 없이 새 데이터에 재적용 가능한 **sklearn.Pipeline** 을 구성했다. 모든 변환기는 학습 fold 에만 fit 한다.

항목	결정	근거
0 sentinel	NaN 변환	trestbps·chol·thalach 의 생리적으로 불가능한 0 처리
연속형 결측	중앙값 대체	이상치·왜도에 강건
범주형 결측	최빈값 대체	가장 흔한 임상 상태로 보수적 대체
스케일링	StandardScaler	LR·SVC 에 필요, 학습 fold 에만 fit (누수 방지)
범주형 인코딩	OneHotEncoder	순서 없는 명목형 변수
이상치	삭제 안 함	920 행 한정 데이터, 대체로 영향만 완화

핵심: 데이터 누수 방지. 스케일러·임퓨터·특성 선택기는 train/validation/test 분할 이후 학습 데이터에만 fit 하고, validation·test·추론 데이터에는 transform 만 적용한다. 교차 검증 시에도 Pipeline 전체가 각 fold 마다 새로 fit 되어 검증 fold 의 정보가 전처리에 새지 않는다.

4. 모델링 · MLflow 실험 및 최종 선택

데이터를 train/validation/test=60/20/20 으로 분할(시드 42, stratify)한 뒤, RandomForest 기반 **SelectFromModel**(threshold='mean')로 9 개 특성을 선택했다. 모든 변환과 특성 선택은 학습 fold 안에서만 fit 된다.

선택 컬럼	RF 중요도
age	0.136
thalach	0.117
chol	0.096
oldpeak	0.080

cp_4.0	0.079
trestbps	0.074
exang_0.0	0.059
exang_1.0	0.057
cp_2.0	0.040

표 1. RandomForest SelectFromModel 특성 선택 결과.

Logistic Regression·SVC·Random Forest 3 개 계열을 학습하고, 모든 실행을 MLflow(SQLite 백엔드)에 파라미터·지표·모델 아티팩트·계열 태그와 함께 기록했다. 전 모델에 5-fold 교차 검증을, RandomForest 에는 RandomizedSearchCV(n_iter=20)를 적용했다. 후보 비교에는 validation 만 사용하고 test 는 최종 선택 후 한 번만 평가했다.

모델	Val Bal. Acc	Precision	Recall	F1	CV Mean
LogisticRegression (선택)	0.801	0.817	0.833	0.825	0.771
SVC	0.773	0.790	0.814	0.802	0.754
RandomForest	0.778	0.792	0.824	0.808	0.775
RandomForest_tuned	0.778	0.792	0.824	0.808	0.790

표 2. Validation 성능 비교 (MLflow 기록). 강조 행이 최종 선택 모델.

최종 선택 후 train+validation 데이터로 다시 학습하고, 보지 않은 테스트셋 184 건을 한 번 평가했다.

모델	TN	FP	FN ↓	TP
LogisticRegression	62	20	20	82

표 3. 독립 테스트셋의 최종 혼동행렬.

최종 모델: LogisticRegression. 독립 테스트셋에서 balanced accuracy 0.780, precision 0.804, recall 0.804, F1 0.804 를 기록했다. 테스트 결과를 모델 선택에 사용하지 않았으므로 이 수치를 최종 일반화 성능 추정치로 해석한다. 기관 하나를 통째로 제외하는 leave-one-site-out 검증의 balanced accuracy 는 0.728 ± 0.054 로, 새 기관 일반화의 불확실성을 별도로 보고한다.

5. 테스트와 패키징 — 무엇을, 왜

단위 테스트 (unittest 7 개) — 실제 데이터·추론 결함을 잡도록 설계:

테스트	검증 내용 / 잡아내는 버그
1. 예측 shape	predict() 행 수 = 입력 행 수. 배치 처리 시 행 누락/중복 탐지
2. 확률 범위·합	predict_proba $\in [0,1]$, 행합은 약 1. 보정·인코딩 깨짐 탐지
3. 입력 범위 검증	chol $\in [1,600]$ 등 임상 범위 초과 입력 차단 (잘못된 단위/오타)
4. 결정론	고정 시드에서 동일 입력 → 동일 출력. 재현성·시드 누락 탐지
5. 결측 sentinel	생리적으로 불가능한 0 측정값이 NaN 으로 정규화되는지 검증
6. 추론 검증 연결	inference.py 가 범위·범주 오류를 예측 전에 실제 차단하는지 검증
7. 숫자 문자열 입력	CSV 숫자 문자열이 수치형으로 정규화돼 추론되는지 검증

Docker. python:3.13-slim 기반으로 requirements 설치 → 코드·모델 복사 → 추론 엔트리포인트를 실행한다.
docker build -t cardiocare:1.0 . 빌드 후 샘플 배치 입력으로 정상 추론된다. 비밀값은 포함하지 않는다.

CI (GitHub Actions). 모든 push 에서 unittest, Docker build, 샘플 컨테이너 추론을 실행한다. main 브랜치의 green 유지를 목표로 한다.

피쳐 스토어 / 모델 레지스트리. 피쳐 스토어에는 oldpeak(ST 하강)를 등록한다 — 현재 실험의 특성 선택에서 채택됐고 임상적 의미가 명확하며, ECG 장비에서 자동 갱신되므로 최신성 관리가 필요하다. 모델 레지스트리에는 recall 값을 메타데이터로 기록해, '기존 배포 모델보다 recall 이 낮은 버전은 Production 승격 불가'라는 안전 게이팅을 자동화한다.

6. 드리프트 결과 및 재학습 / 피드백 루프

테스트셋의 chol 평균을 +30, 분산을 1.5 배로 인위 이동시킨 뒤, 각 연속형 특성에 대해 학습 분포와 `scipy.stats.ks_2samp` 를 수행했다.

특성	KS 통계량	p-value	드리프트 플래그
age	0.0408	9.63e-01	—
trestbps	0.0405	9.68e-01	—
chol	0.2489	1.14e-06	플래그
thalach	0.0578	7.10e-01	—
oldpeak	0.0411	9.64e-01	—

표 4. KS 검정 결과 — 드리프트를 주입한 chol 만 정확히 플래그됨.

검정은 드리프트를 주입한 chol 만 플래그했다. 그러나 balanced accuracy 는 0.780 → 0.780 로, 이 시뮬레이션에서는 즉각적인 성능 저하가 관찰되지 않았다. 따라서 분포 드리프트 탐지와 성능 저하를 동일시하지 않고, 실제 라벨 기반 성능 모니터링을 별도로 유지해야 한다.




그림 3. 합성 타임스탬프 기반 드리프트 모니터링 — chol 평균이 점증할수록 KS p-value 는 급락하지만 balanced accuracy 는 단조 하락하지 않음.

재학습 / 피드백 전략

- 트리거 기반 재학습: 핵심 특성의 KS $p < 0.05$ 가 일정 기간 지속되거나, 라벨 확보 후 balanced accuracy 가 임계치 이하로 떨어지면 재학습을 트리거한다.
- 정기 재학습: 트리거가 없어도 분기별로 최신 임상 데이터로 재학습해 점진적 드리프트에 대비한다.

- 폭주 피드백 루프 위험: 모델 예측을 그대로 라벨로 재사용하면, 모델이 놓친 양성(FN)이 학습 데이터에서도 음성으로 굳어져 recall 이 자기강화적으로 악화된다. 이를 막으려면 재학습 라벨은 모델 출력이 아니라 의사의 확진/추적 결과 같은 실제 정답만 사용해야 한다.
- Human-in-the-loop 지점: (1) 경계 확률(예: 0.4~0.6) 구간은 의사 검토로 라우팅, (2) 재학습된 모델은 recall 게이팅 통과 후 사람이 승인해야 배포, (3) 드리프트 알람은 자동 재배포가 아니라 담당자에게 통지된다.

7. 서빙 선택: Model-as-a-Service

운영 확장안으로 Model-as-a-Service(MaaS)를 선택한다. 현재 저장소 구현은 입력 검증이 포함된 CSV 배치 추론 CLI이며, 병원 EMR 연동 중앙 API 는 다음 배포 단계의 목표 구조다.

기준	MaaS 선택 근거
지연 시간	심장병 선별은 실시간(ms) 요구가 아닌 진료 중 수초 내 응답으로 충분 → 서버 추론 적합
모델·로그를 병개인증정보(PHI)원 통	제하의 보안 서버에 중앙 집중 → 감사·접근통제·규정 준수 용이. 단, 전송 구간 암호화 필요
업데이트 주기재학	모델을 단일 엔드포인트에 즉시 배포 → 전 사용자가 동일 최신 버전 사용, 기기별 배포

호화와 PHI 최소
수집은 필수

불필요

On-Device 는 오프라인 동작과 데이터 미전송이라는 장점이 있으나, 모델 갱신 배포가 기기마다 분산되고 버전 파편화·드리프트 모니터링이 어렵다. 병원 환경에서는 중앙 통제와 감사 가능성이 더 중요하므로 MaaS 가 적합하다.

8. 한계, 윤리적 고려, 추가 작업

한계

- 표본이 920 행으로 작고 4 개 기관에 한정 → 다른 인구집단으로의 일반화가 제한적이다.
- slope-cohort 의 높은 결측을 대치로 메웠으므로, 해당 특성의 신호가 약화됐을 수 있다.
- 1999 년 전후 데이터로, 현재 임상 분포와 시점 드리프트가 존재할 수 있다.

윤리적 고려

CardioCare 는 의사를 대체하지 않고 보조한다(inform, not decide). 오분류의 비용이 환자 안전과 직결되므로, 예측은 항상 의료 전문가의 검토를 거쳐야 한다. 성별·연령 등 민감 변수에 따른 성능 편향 점검과, 환자에게 'AI 보조 사용' 사실을 고지하는 절차가 운영 단계에서 필요하다. recall 을 우선했어도 놓치는 환자(FN)는 여전히 존재하므로, 음성 결과가 곧 안전을 보장하지 않음을 사용자에게 명확히 전달해야 한다.

1 주가 더 주어진다면

- 결정 임계값을 0.5 가 아닌 recall 목표(예: ≥ 0.90)에 맞춰 보정하고 PR 곡선으로 운영점 선택.
- SHAP 기반 설명을 추가해 의사가 예측 근거를 검토할 수 있게 함.
- 성별·연령 하위 그룹별 공정성 지표(subgroup recall)를 측정하고 보고.
- MLflow Model Registry 와 실제 드리프트 대시보드를 연동.

부록 A. AI 도구 사용 공개

본 프로젝트에서 AI 코딩 도우미(Claude, OpenAI Codex)를 보일러플레이트 작성과 디버깅 보조 용도로 사용했다. 구체적으로는 sklearn Pipeline·MLflow·unittest·Dockerfile 의 표준 구조 초안 작성, 데이터 누수 점검, 입력 검증, reportlab 보고서 레이아웃과 버전 호환 오류 디버깅에 활용했다.